

MABe Challenge 小鼠社会行为识别比赛总结

一、比赛概述

MABe Challenge (Multi-Agent Behavior Challenge) 是面向多智能体动物行为识别的国际性竞赛。该比赛是由加州理工学院、西北大学等机构联合发起的，目标是利用机器学习方法自动识别动物复杂社会行为，例如攻击、防御、筑巢、理毛、抚养幼崽和照顾同伴等。传统动物行为研究高度依赖人工标注，不仅耗时，而且容易受到主观判断影响。MABe 的意义在于把动物行为分析从人工、低通量、强经验依赖的流程，推进到自动化、标准化和可迁移的机器学习流程。

本次比赛聚焦“小鼠社交行为识别”。参赛者并不直接处理原始视频帧，而是基于俯视视频中已经提取出的小鼠姿态关键点数据，建立模型识别 38 种社交与非社交行为。因此，这个任务可以归类为计算机视觉中的姿态序列行为识别，也涉及时间序列建模、数据挖掘和多智能体交互建模。

项目	说明
比赛名称	MABe Challenge - Social Action Recognition in Mice
任务方向	计算机视觉、姿态序列分析、时序建模、数据挖掘
核心目标	基于俯视视频提取的小鼠姿态关键点，识别 38 种社交与非社交行为
评价指标	加权 F-Score：先在单个实验室内平均，再按视频与行为层级汇总
公开 / 私有榜	公开榜使用测试集 32%，私有榜使用测试集 68%
比赛时间	2025-09-18 开始；2025-12-08 截止提交；2025-12-16 公布成绩
奖金设置	第 1 名 20,000 美元；第 2 名 10,000 美元；第 3 名 8,000 美元；第 4 名 7,000 美元；第 5 名 5,000 美元

二、比赛意义

MABe Challenge 不只是一个单纯的算法比赛，它更像是“行为组学”走向大规模自动分析的一次标准化尝试。不同实验室的数据被汇聚到同一竞赛框架下，参赛模型需要面对不同设备配置、拍摄条件、关键点定义和标注习惯带来的分布差异。这种设置使比赛具有很强的真实科研应用价值：一个优秀模型不仅要在训练集上表现好，更要能迁移到新的实验室和新的动物行为场景。

从学科价值上看，该类模型能够帮助神经科学、计算生物学、动物行为学和生态学研究更高效地分析动物社会结构、互动模式和行为变化。它把人工智能技术引入生命科学实验流程中，使原本依赖人工观察的行为分析任务变得更自动、更可复现，也更容易在多个实验室中部署。

三、核心建模难点

- 跨实验室泛化：不同实验室的 arena 尺寸、拍摄条件、帧率、标注策略和关键点集合并不一致，模型容易学习到实验室特有偏差。
- 姿态关键点不统一：部分实验室追踪 hip，部分实验室追踪 lateral，不同数据源可用身体部位不同，需要做特征对齐。
- 动作类别不均衡：常见动作样本很多，稀有动作样本较少，直接用 argmax 容易偏向高频动作。
- 行为具有时间连续性：动作不是孤立帧标签，而是一段持续的时序片段，因此需要滑动窗口、概率平滑和边界后处理。

- 5、标签合法性约束复杂：并非每个视频都标注所有行为，训练和推理时需要屏蔽当前视频不可能出现或未纳入标注范围的动作。
- 6、多动作冲突：同一帧可能有多个动作得分超过阈值，需要设计合理的冲突解决机制，而不能简单选择绝对概率最高的类别。

四、主流技术路线

赛后方案大体形成了两条技术路线：一类是以手工特征工程为核心的梯度提升树路线，代表模型包括 XGBoost、CatBoost 和 LightGBM；另一类是以端到端时序建模为核心的神经网络路线，代表模型包括 LSTM、GRU、CNN-Transformer、Transformer 和 SqueezeFormer。高分方案通常不是只依赖单一模型，而是把二者结合起来，通过集成或堆叠进一步提升稳定性。

4.1 决策树 / GBDT 路线

GBDT 路线的核心是“先把姿态序列转化为可解释的行为特征，再用树模型分类”。常见特征包括身体部位之间的距离、角度、速度、加速度、主体小鼠与目标小鼠之间的跨体距离，以及以小鼠自身为中心的 ego-centric 坐标。该路线的优势是训练相对稳定、特征重要性更容易解释，且在数据量有限或关键点质量不一的情况下往往比较稳。

优秀的树模型方案通常会按实验室单独建模，或至少在验证时严格考虑实验室分布。原因是不同实验室的数据分布差异很明显，把所有来源简单混合可能导致模型在本地 CV 上虚高，却在线上私榜泛化不足。

4.2 神经网络路线

神经网络路线更关注端到端的时序行为模式学习。模型会把连续多帧的姿态特征作为输入，通过 LSTM、GRU、CNN-Transformer 或 Transformer 捕捉短期动作变化和长期行为上下文。为了增强泛化能力，高分方案普遍不直接使用原始绝对坐标，而是构造相对距离、速度、加速度、自我中心坐标或归一化后的 arena 坐标。

该路线常配合多尺度滑动窗口，例如 64、128、256 和 512 帧，以覆盖短动作和长动作。训练时通常采用 one-vs-rest 二元交叉熵，并对当前视频中不合法的动作做 mask，避免模型对不可能出现的类别学习错误监督信号。

4.3 后处理共识

后处理是本次比赛的关键增分点。高分方案普遍不使用固定全局阈值，而是为每个“实验室 x 动作”组合单独搜索阈值。推理得到帧级概率后，还会进行时间平滑，例如 EMA 或双向 EMA，以减少预测抖动。若多个动作同时超过阈值，常见决策方式包括“概率 / 阈值”比值或 Z 分数，而不是简单选择概率最大的类别。

五、重要公开代码与参考资料

比赛过程中，社区公开了一些可复现的 baseline 和改进方案，包括 XGBoost、Extra Trees、LGB/XGB/CatBoost 融合等。这些代码适合用作个人项目的起点：先复现公开 baseline，再逐步加入特征工程、阈值搜索、平滑后处理和模型融合。

资源	链接
XGBoost baseline	https://www.kaggle.com/code/ravaghi/social-action-recognition-in-mice-xgboost
Extra Trees GPU	https://www.kaggle.com/code/mattiaangeli/mabe-extra-trees-gpu
LGB + XGB + CatBoost	https://www.kaggle.com/code/kerta27/mabe-lgb-xgb-catboost
2nd place solution	https://www.kaggle.com/competitions/MABe-mouse-behavior-detection/writeups/2nd-place-solution
3rd place solution	https://www.kaggle.com/competitions/MABe-mouse-behavior-detection/writeups/3rd-place-solution
7th place solution	https://www.kaggle.com/competitions/MABe-mouse-behavior-detection/writeups/7th-place-gold-cnn-transformer-with-invariant-fe
15th place solution	https://www.kaggle.com/competitions/MABe-mouse-behavior-detection/writeups/15th-place-solution

六、高分方案整理

6.1 第 2 名金牌方案：solo / pair 任务拆分与深度时序模型

第 2 名方案将独处行为（solo）和成对行为（pair）分别建模。所有输入数据被统一处理为 30 FPS 时间序列，25 FPS 数据的标签帧号按 30/25 比例缩放以完成对齐。缺失值通过线性插值填补；若某帧部分关键点缺失，则用同帧其他部位坐标均值替代；距离、速度和加速度等动态特征使用预计算统计量标准化。

特征层面，该方案同时使用每帧共享元特征和动态运动特征。元特征包括小鼠性别、帧率缩放因子、实验室 ID 嵌入和候选动作类别；动态特征包括身体部位间距离、速度、加速度，以及 pair 行为中两只小鼠之间的跨体部位距离。模型架构包括多尺度卷积后接双向 GRU 或 Transformer 的 CNN+RNN/Transformer 结构，以及 SqueezeFormer 编码器。

训练时采用 5 折分层交叉验证，每个动作以 one-vs-rest 方式训练，损失函数为 BCE。优化中使用 warmup + 余弦退火学习率、EMA，并在验证集上针对每个“实验室 x 动作”搜索最优阈值。推理阶段采用 512 帧窗口、128 帧步长，每个窗口丢弃首尾 32 帧并对中间预测取平均，同时使用左右翻转 TTA。其核心增益来自帧率对齐、任务拆分、阈值优化和精细后处理。

6.2 第 3 名金牌方案：LSTM 与 XGBoost 融合

第 3 名方案采用神经网络与 XGBoost 的融合策略，整体流程以特征工程为核心。团队构建了约 60 个手工特征，包括身体关键点之间的距离、角度、速度等运动学量，以及实验室来源等元信息。为了提升跨实验室泛化能力，他们整合全部实验室数据，并统一选取多数数据集中都存在的 5 个身体关键点作为建模基础。

神经网络部分使用 LSTM 后接全连接层，通过 softmax 输出允许动作类别，并对非法动作进行掩码。实验室编号被编码为可学习嵌入向量，作为额外输入注入模型，使网络能够自适应不同实验环境差异。XGBoost 则在公开强 baseline 基础上进一步增强，包括新增特征、删除低重要性冗余特征、基于 F1 早停、概率平滑和超参数优化。最终多个 LSTM 与 XGBoost 变体进行加权融合。

后处理阶段，该方案在 OOF 预测上按“实验室 x 动作”网格搜索阈值。当同一帧多个动作超过阈值时，保留“概率 / 阈值”最高的动作，以缓解多标签冲突。该方案的启发是：树模型和神经网络并不是替代关系，前者擅长利用稳定手工特征，后者擅长捕捉时序上下文，融合后往往更稳。

6.3 第 7 名金牌方案：不变性特征 + CNN-Transformer + XGBoost 堆叠

第 7 名方案的核心思想是构建对实验室差异具有不变性的深度学习特征，并结合 CNN-Transformer 和 XGBoost 后融合策略。该方案首先处理不同实验室 arena 尺寸、形状和关键点定义不一致的问题。方法包括：以主体小鼠双耳中点为原点构造自我中心坐标；旋转坐标系使尾根朝向负 y 轴；使用 5% 和 95% 分位数做 min-max 缩放；或直接放弃绝对坐标，使用身体部位之间的相对距离。

对于不同实验室关键点命名不一致的问题，该方案将 hip 和 lateral 统一重命名为 side_left 和 side_right，从而提升跨实验室特征对齐程度。模型采用 CNN-Transformer 混合结构：一维卷积负责提取局部时序模式，Transformer 负责建模长程依赖与主体-目标小鼠之间的交互。训练标签采用“正样本-负样本-掩码”三态策略，避免非法动作参与损失计算。

训练时使用 64、128、256、512 帧多尺度滑动窗口，并加入时间尺度扰动、随机旋转、坐标缩放、水平翻转、左右部位互换、随机丢弃身体部位等增强方式。最终方案包含三个特征家族、10 个 CNN-Transformer 模型等权集成，并在此基础上叠加 XGBoost，以 OOF 预测和手工特征作为输入，为每个实验室和动作单独训练二层模型。该方案充分体现了“特征不变性 + 多尺度时序建模 + stacking”的思路。

6.4 第 15 名银牌方案：XGBoost / CatBoost 与统计后处理

第 15 名方案以公开 XGBoost baseline 为基础，重点放在训练数据筛选、特征表达和后处理决策上。方案首先剔除了测试集中不存在的数据源，如 CalMS21、MABe22 和 CRIM13，以提高本地 CV 与线上 LB 的相关性；同时移除 AdaptableSnail 中部分 25 FPS 低质量数据，避免噪声影响模型训练。

特征工程方面，该方案引入 ego-centric 坐标系统，以小鼠身体中心为原点；若没有 body_center，则使用当前帧所有关键点均值近似替代。随后将坐标系旋转，使小鼠运动方向对齐正 Y 轴，从而降低绝对位置和朝向变化对模型的干扰。模型上使用 XGBoost 和 CatBoost，并为每个实验室单独训练模型，以适配实验室间分布差异。

后处理是该方案的亮点。它没有直接用 argmax，而是引入 Z 分数： $z = (\text{预测概率} - \text{阈值}) / \sigma$ ，其中 σ 为该动作在 OOF 预测中的标准差。多个动作同时超过阈值时，选择 Z 分数最高者，使决策更关注“超出阈值的显著程度”。此外，方案还对概率应用双向 EMA 平滑，有效减少帧级预测抖动。

七、高分方案对比

名次	主要模型	核心思路	关键细节	可借鉴点
第 2 名（金牌）	CNN+GRU/Transformer、SqueezeFormer	将 solo 与 pair 行为分开建模，以 30 FPS 为统一时间基准。	线性插值补缺失；one-vs-rest BCE；5 折分层交叉验证；按“实验室 x 动作”搜索阈值；滑动窗口 512/128；TTA；针对 25 FPS 数据做边界校正。	任务拆分、帧率统一、阈值精调、推理窗口重叠平均。
第 3 名（金牌）	LSTM + XGBoost	神经网络与树模型融合，兼顾时序模式学习和手工特征表达。	约 60 个手工特征；统一 5 个常见身体关键点；实验室 ID 作为嵌入；XGBoost 做特征增强、剪枝、F1 早停与概率平滑。	模型融合、实验室嵌入、特征工程与神经网络互补。
第 7 名（金牌）	CNN-Transformer + XGBoost 堆叠	围绕跨实验室泛化构造	主体小鼠中心坐标系；	不变性特征、多尺度建

		位置不变、方向不变、关键点对齐的深度特征。	arena min-max 缩放；hip/lateral 合并为 side；64-512 帧多尺度窗口；三态标签；10 个 CNN-Transformer 集成；OOF 预测叠加 XGBoost。	模、掩码标签、堆叠集成。
第 15 名（银牌）	XGBoost + CatBoost	基于公开 XGBoost 基线，依靠数据筛选、实验室独立建模和后处理提升稳定性。	剔除测试集未见来源与低质量 25 FPS 数据；自我中心坐标；特征剪枝；每个实验室单独训练；Z 分数决策；双向 EMA 平滑。	可靠 CV 构建、按实验室建模、公平后处理、时间平滑。

八、对个人 GitHub 项目的启发

如果把该比赛沉淀成个人 GitHub 项目，不建议只上传两个 **notebook**。更好的做法是把它整理为一个完整的机器学习项目：**README** 说明任务背景和技术路线，**notebook** 展示训练与推理流程，文档总结高分方案，**requirements.txt** 记录依赖，后续再补充流程图、特征说明和结果示例。

- 1、项目定位：计算机视觉 / 姿态序列行为识别 / 时序建模 / 数据挖掘。
核心能力展示：理解真实竞赛任务，能复现公开 **baseline**，能总结高分方案，能做特征工程和后处理。
- 2、代码整理重点：将训练和推理分离，重命名函数与变量，增加注释，清空 **notebook** 输出，避免上传大数据文件。
- 3、文档整理重点：保留比赛背景、任务目标、评价指标、技术路线、高分方案和个人复盘，而不是只放原始赛题说明。
- 4、后续优化方向：补充可视化、加入流程图、将 **notebook** 重构为 **src** 脚本、写出 **baseline** 到改进版的实验对比。

九、总结

MABe Challenge 的本质，是基于姿态关键点序列的小鼠社会行为识别任务。它表面上属于计算机视觉比赛，但核心难点并不只是“看见小鼠”，而是如何把姿态点、运动学特征、实验室差异、时间连续性和行为合法性共同纳入模型。高分方案的共同经验可以概括为三点：第一，直接使用原始坐标很难泛化，需要构造相对位置、自我中心坐标和跨体距离等不变性特征；第二，时序建模和手工特征并不冲突，神经网络与 **GBDT** 的融合往往更稳；第三，阈值搜索、概率平滑和冲突决策等后处理在该类帧级行为识别任务中非常关键。

对于个人项目展示而言，这个比赛非常适合用来体现机器学习竞赛思维：既有真实科研应用背景，又有复杂数据分布和高分方案可复盘。将其整理成 **GitHub** 项目时，应突出“姿态序列行为识别、跨实验室泛化、特征工程、时序模型、模型融合和后处理”这些关键词。